

# 补充

## 1. $\chi^2$ 分布 (卡方分布)

**核心直觉：**它是“误差的平方和”。用于描述方差的波动。

### 定义与构造

设  $X_1, X_2, \dots, X_n$  相互独立，且都服从标准正态分布  $N(0, 1)$ ，那么它们的平方和： $Y = \sum_{i=1}^n X_i^2$  服从自由度为  $n$  的  $\chi^2$  分布，记为  $Y \sim \chi^2(n)$ 。

- 自由度 ( $n$ )：**参与求和的独立标准正态变量的个数。

### 关键性质

- 取值范围：** $(0, +\infty)$  (因为是平方和，肯定是正的)。
- 期望与方差：**
  - $E(Y) = n$
  - $Var(Y) = 2n$
- 可加性：**如果  $Y_1 \sim \chi^2(n_1)$ ,  $Y_2 \sim \chi^2(n_2)$  且独立，那么  $Y_1 + Y_2 \sim \chi^2(n_1 + n_2)$ 。
- 大样本：**当  $n$  很大时， $\chi^2(n)$  趋近于正态分布。

### 主要用途

- 检验方差：**推断正态总体的方差 (如  $\sigma^2$  的置信区间)。
- 拟合优度检验：**判断数据是否符合某种分布。
- 列联表分析：**独立性检验 (卡方检验)。

## 2. $t$ 分布 (学生氏 $t$ 分布)

**核心直觉：**它是“小样本下的正态分布”。当我们不知道总体标准差  $\sigma$ ，只能用样本标准差  $S$  代替时，就不再是正态分布，而是  $t$  分布。

### 定义与构造

设  $X \sim N(0, 1)$ ,  $Y \sim \chi^2(n)$ ，且  $X$  与  $Y$  相互独立，则变量： $T = \frac{X}{\sqrt{Y/n}}$

服从自由度为  $n$  的  $t$  分布，记为  $T \sim t(n)$ 。

- 口诀：**“上边是标准正态，下边是根号下的卡方除以自由度”。

### 关键性质

- 形态：**钟形曲线，关于  $x = 0$  对称。
- 与正态分布的区别：“厚尾”。** $t$  分布的尾部比标准正态分布略高，中间略低。这意味着小样本情况下，极端值出现的概率比正态分布预测的要大。
- 极限：**当自由度  $n \rightarrow \infty$  时， $t(n)$  收敛于标准正态分布  $N(0, 1)$ 。

### 主要用途

- 均值检验：**在方差未知的情况下，检验正态总体的均值 ( $t$ -test)。
- 回归系数检验：**线性回归中检验系数是否显著不为0。

### 3. F 分布

**核心直觉：**它是“两个方差的比值”。用于比较两个群体的波动程度是否一致。

#### 定义与构造

设  $U \sim \chi^2(n_1)$ ,  $V \sim \chi^2(n_2)$ , 且  $U$  与  $V$  相互独立, 则变量:  $F = \frac{U/n_1}{V/n_2}$

服从自由度为  $(n_1, n_2)$  的  $F$  分布, 记为  $F \sim F(n_1, n_2)$ 。

- 口诀：**“两个卡方分布, 分别除以自己的自由度, 然后再相除”。

#### 关键性质

- 取值范围：** $(0, +\infty)$ 。
- 倒数性质：**如果  $X \sim F(n_1, n_2)$ , 那么  $\frac{1}{X} \sim F(n_2, n_1)$ 。这在查表和计算置信区间时非常有用。
- 非对称：**偏态分布, 向右拖尾。

#### 主要用途

- 方差分析 (ANOVA):** 比较三个或更多组的均值是否存在显著差异 (本质是在比组间方差和组内方差)。
- 等方差检验:** 检验两个正态总体的方差是否相等 (F-test)。

### 4. 泊松分布

若随机变量  $X$  服从参数为  $\lambda$  的泊松分布, 记为  $X \sim P(\lambda)$  或  $X \sim \text{Poi}(\lambda)$ 。

其概率质量函数为:  $P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$ ,  $k = 0, 1, 2, \dots$

期望:  $E[X] = \lambda$

方差:  $\text{Var}(X) = \lambda$

### 5. 指数分布

若随机变量  $X$  服从参数为  $\lambda$  ( $\lambda > 0$ ) 的指数分布, 记为  $X \sim \text{Exp}(\lambda)$ 。

- 概率密度函数 (PDF):**  
描述了在某一点取值的相对可能性。可以看到随着  $x$  增加, 概率密度呈指数衰减。

$$f(x; \lambda) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

这里  $\lambda$  被称为**率参数 (Rate Parameter)**, 表示单位时间内事件发生的平均次数。

- 累积分布函数 (CDF):**

$$F(x; \lambda) = \begin{cases} 1 - e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

#### 期望与方差 (Mean & Variance)

指数分布的均值和方差都仅依赖于参数  $\lambda$ 。

- 期望 (Mean):**  $E[X] = \frac{1}{\lambda}$ 
  - 注意：**如果  $\lambda$  是故障率 (每小时坏几次), 那么  $1/\lambda$  就是平均故障间隔时间。
- 方差 (Variance):**  $\text{Var}(X) = \frac{1}{\lambda^2}$

## 6. 几何分布

### 概率质量函数 (PMF)

对于定义 A (第  $k$  次才成功) :  $P(X = k) = (1 - p)^{k-1}p$

### 累积分布函数 (CDF)

$$P(X \leq k) = 1 - (1 - p)^k$$

无记忆性 —— 最独特的性质

$$\text{期望值: } E[X] = \frac{1}{p}$$

$$\text{方差: } Var(X) = \frac{1-p}{p^2}$$

## 7. 二项分布

### 概率质量函数 (PMF):

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n$$

性质:

- 期望:  $E(X) = np$
- 方差:  $Var(X) = np(1 - p)$

## 8. 均匀分布

### 概率密度函数 (PDF):

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{其他} \end{cases}$$

性质:

- 期望:  $E(X) = \frac{a+b}{2}$  (区间的中点)
- 方差:  $Var(X) = \frac{(b-a)^2}{12}$

## 9. 分位数

(1) 对标准正态分布  $N(0,1)$ , 用  $z_p$  表示其分布的  $p$  分位数, 即  $P\{X \leq z_p\} = p$

由于标准正态分布的概率密度函数图形关于  $y$  轴对称, 因此有  $-z_p = z_{1-p}$ 。

(2) 对自由度为  $n$  的  $\chi^2$  分布  $\chi^2(n)$ , 用  $\chi_p^2(n)$  表示其分布的  $p$  分位数, 即  $P\{\chi^2 \leq \chi_p^2(n)\} = p$

(3) 对自由度为  $n$  的  $t$  分布  $t(n)$ , 用  $t_p(n)$  表示其分布的  $p$  分位数, 即  $P\{T \leq t_p(n)\} = p$

由于  $t$  分布的概率密度函数图形关于  $y$  轴对称, 因此有  $-t_p(n) = t_{1-p}(n)$ 。

(4) 对自由度为  $n_1, n_2$  的  $F$  分布  $F(n_1, n_2)$ , 用  $F_p(n_1, n_2)$  表示其分布的  $p$  分位数, 即  $P\{F \leq F_p(n_1, n_2)\} = p$ , 且有  $F_p(n_2, n_1) = \frac{1}{F_{1-p}(n_1, n_2)}$

## 第一章

### 频率估计概率

这是概率论中最基础的思想之一, 也是“频率学派”统计学的核心基石。

- **定义：**在大量重复进行的独立试验中，如果某个事件  $A$  发生的次数为  $m$ ，试验总次数为  $n$ ，那么频率  $f_n(A) = \frac{m}{n}$ 。当  $n$  趋于无穷大时，频率会稳定在某个常数附近，我们用这个频率值作为该事件概率  $P(A)$  的估计值。
- **公式：**  $\hat{p} = \frac{m}{n}$

## 矩估计法

矩估计法的基本方程组就是令：

总体原点矩 = 样本原点矩

$$E[X^k] = \frac{1}{n} \sum_{i=1}^n X_i^k$$

### 一阶矩估计

**一阶矩**即  $k = 1$  时的矩，也就是我们最熟悉的**期望（均值）**。

- **总体一阶矩：**  $E[X] = \mu$  (理论上的均值)
- **样本一阶矩：**  $A_1 = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  (样本的平均值)

### 二阶矩估计

**二阶矩**即  $k = 2$  时的矩，描述的是数据的平方的期望。它通常与**方差**密切相关，因为  $\text{Var}(X) = E[X^2] - (E[X])^2$ 。

- **总体二阶矩：**  $E[X^2]$
- **样本二阶矩：**  $A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$  (样本平方的平均值)

## 充分统计量

**定理：** 设总体分布族为  $\{P_\theta, \theta \in \Theta\}$ ,  $T(X)$  是充分的，当且仅当存在一个定义在  $I \times \Theta$  上的函数  $g(t, \theta)$  及定义在  $R^n$  上的函数  $h(x)$  使得

$$p(x, \theta) = g(T(x), \theta)h(x)$$

对所有的  $x \in R^n$  都成立，其中  $I$  是  $T(x)$  的值域， $p(x, \theta)$  是样本的联合概率密度函数或分布率。 $T(x)$  为充分统计量。

$\bar{y}$ 和 $\sum (y_i - \bar{y})^2$

样本均值  $\bar{y}$  与 样本离差平方和  $\sum (y_i - \bar{y})^2$  相互独立。

## 极大似然估计的不变性原理

如果  $\hat{\theta}$  是参数  $\theta$  的极大似然估计，而  $g(\theta)$  是  $\theta$  的一个函数，那么  $g(\hat{\theta})$  就是  $g(\theta)$  的极大似然估计。

## 均方误差 (MSE)

$$MSE(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + [\text{Bias}(\hat{\theta})]^2$$

## 充分完备统计量

设  $x_1, x_2, \dots, x_n$  是来自总体  $\{P_\theta : \theta \in \Theta\}$  的简单样本，总体的密度函数（或分布列）为  $p(x; \theta)$ ，且样本  $x_1, x_2, \dots, x_n$  的联合密度函数（或联合分布列）可分解为

$$p(x_1, x_2, \dots, x_n; \theta) = c(\theta)h(x_1, x_2, \dots, x_n) \exp\{\sum_{k=1}^m w_k(\theta)T_k(x_1, x_2, \dots, x_n)\}$$

其中  $h(x_1, x_2, \dots, x_n)$  仅是  $x_1, x_2, \dots, x_n$  的函数,  $w = w(\theta) = (w_1(\theta), \dots, w_m(\theta))$  是定义在  $m$  维参数空间  $\Theta$  上取值于  $\Lambda \subset \mathbf{R}^m$  的向量函数,  $c(\theta)$  仅是  $\theta$  的函数。如果  $w(\theta)$  值域  $\Lambda$  包含内点, 则  $m$  维统计量  $T(x_1, x_2, \dots, x_n) = (T_1(x_1, x_2, \dots, x_n), T_2(x_1, x_2, \dots, x_n), \dots, T_m(x_1, x_2, \dots, x_n))$  是完全充分的。

## UMVUE

设  $S(x)$  是完全充分统计量,  $\varphi(x)$  是  $q(\theta)$  的方差有限的无偏估计, 即  $\varphi(x) \in U_q$ , 则

$$T(x) = E_{\theta}(\varphi(x) | S(x))$$

是  $q(\theta)$  **唯一**的一致最小方差无偏估计 (UMVUE)。

- 其一, 若能获得  $q(\theta)$  的无偏估计  $\varphi(x)$ , 则  $\varphi(x)$  关于  $S(x)$  的条件数学期望  $T(x) = E_{\theta}(\varphi(x) | S(x))$  就是  $q(\theta)$  的一致最小方差无偏估计;
- 其二, 由于  $q(\theta)$  的一致最小方差无偏估计  $T(x)$  一定是完全充分统计量  $S(x)$  的函数, 所以若能获得完全充分统计量  $S(x)$  的函数  $h(S(x))$ , 并将其无偏化, 就可获得  $q(\theta)$  的一致最小方差无偏估计。

## Fisher 信息量

$$I(\theta) = E \left[ \left( \frac{\partial}{\partial \theta} \ln f(X; \theta) \right)^2 \right] = -E \left[ \frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) \right]$$

## 有效估计

**定义 2.3.2** 设分布族  $\{P_{\theta} : \theta \in \Theta\}$  是 Cramer-Rao 正则族,  $q(\theta)$  是可估参数, 若存在某个无偏估计  $\hat{q} \in U_q$ , 对所有的  $\theta \in \Theta$ , 有  $\text{Var}_{\theta}(\hat{q}) = \frac{[q'(\theta)]^2}{nI(\theta)}$ , 则称  $\hat{q}$  为参数  $q(\theta)$  的有效估计。

**定义 2.3.3** 对可估参数  $q(\theta)$  的任一无偏估计  $T \in U_q$ , 令  $e(T, q(\theta)) = \frac{[q'(\theta)]^2}{nI(\theta)} / \text{Var}_{\theta}(T)$ , 则称  $e(T, q(\theta))$  为使用  $T$  估计  $q(\theta)$  的有效率。

## 渐近无偏估计

设  $\hat{\theta}_n$  是基于  $n$  个样本对参数  $\theta$  的估计量。如果满足以下极限条件:  $\lim_{n \rightarrow \infty} E[\hat{\theta}_n] = \theta$

或者等价地写成偏差 (Bias) 趋于 0:  $\lim_{n \rightarrow \infty} \text{Bias}(\hat{\theta}_n) = \lim_{n \rightarrow \infty} (E[\hat{\theta}_n] - \theta) = 0$ , 则称  $\hat{\theta}_n$  是  $\theta$  的渐近无偏估计。

## Cramér-Rao 不等式

对于单参数  $\lambda$  的函数  $g(\lambda)$ , 如果  $T$  是它的无偏估计量, 那么  $T$  的方差一定满足以下不等式:

$$\text{Var}(T) \geq \frac{[g'(\lambda)]^2}{I_n(\lambda)}$$

其中:

- 分子**  $[g'(\lambda)]^2$  是你想要估计的函数对参数求导后的平方。
- 分母**  $I_n(\lambda)$  是样本的 **Fisher 信息量 (Fisher Information)**。

## 相合估计

如果  $\hat{q}_n(X)$  是参数  $q(\theta)$  **相合**估计, 且函数  $h(y)$  在  $y = q(\theta)$  处连续, 则  $h(\hat{q}_n)$  是  $h(q(\theta))$  的**相合**估计。

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta \quad \text{且} \quad \lim_{n \rightarrow \infty} D(\hat{\theta}_n) = 0$$

(或者写成:  $\hat{\theta}_n$  的均方误差趋于 0, 即  $\lim_{n \rightarrow \infty} E[(\hat{\theta}_n - \theta)^2] = 0$ )

## 第二章

### 势和势函数

#### ☑ 势 (Power): 正确拒绝 $H_0$ 的能力

当  $H_0$  不成立时, 我们 **正确拒绝**  $H_0$  的概率, 叫做检验的势或功效。

- ◇ 定义:  $\gamma(\theta) = P_\theta\{x \in W\} = 1 - \beta(\theta)$ ,  $\theta \in \Theta_1$
- ☑ 所以: 势 = 1 - 第二类错误概率

#### ☑ 势函数 (功效函数)

把检验的“势”看成关于参数  $\theta$  的函数, 就是 **势函数** (也叫功效函数):

$$g(\theta) = P_\theta\{x \in W\} = E_\theta[\varphi(x)], \quad \theta \in \Theta$$

其中:

- $g(\theta)$  表示当真实参数为  $\theta$  时, 拒绝  $H_0$  的概率。
- 当  $\theta \in \Theta_0$  时,  $g(\theta) = \alpha(\theta)$  (第一类错误概率)
- 当  $\theta \in \Theta_1$  时,  $g(\theta) = \gamma(\theta)$  (势)

### 两类错误

#### ☑ 1. 第一类错误 (弃真错误)

当  $H_0$  实际上成立, 但我们却错误地拒绝了它。

- ◇ 定义:  $\alpha(\theta) = P_\theta\{x \in W\}$ ,  $\theta \in \Theta_0$
- $\alpha(\theta)$  是当参数取  $\theta \in \Theta_0$  (即  $H_0$  成立) 时, 样本落入拒绝域的概率。
- 也就是犯第一类错误的概率。

#### ☑ 2. 第二类错误 (取伪错误)

当  $H_0$  实际上不成立 (即  $H_1$  为真), 但我们却错误地接受了  $H_0$ 。

- ◇ 定义:  $\beta(\theta) = P_\theta\{x \notin W\} = 1 - P_\theta\{x \in W\}$ ,  $\theta \in \Theta_1$
- 即当  $H_1$  成立时, 样本落在接受域的概率。
- 也就是犯第二类错误的概率。

### Neyman-Pearson 假设检验原理

为了处理这个矛盾 (指无法同时降低两类错误), 统计学家 Neyman 和 Pearson 提出了一个普遍做法:

✧ 固定第一类错误的概率不超过某个小值  $\alpha$ , 然后在所有满足这一条件的检验中, 寻找势最大 (即第二类错误最小) 的那个检验。

### 一致最优检验

设总体分布族为  $\{p(x; \theta) : \theta \in \Theta\}$ , 考虑假设检验问题,  $H_0 : \theta \in \Theta_0$ ,  $H_1 : \theta \in \Theta_1$ , 将水平为  $\alpha$  的所有检验函数的集合记为  $\Phi_\alpha = \{\varphi(x) : \sup_{\theta \in \Theta_0} E_\theta \varphi(x) \leq \alpha\}$ , 定义最优势检验如下。

对假设检验问题，若存在水平为  $\alpha$  的检验函数  $\varphi^* \in \Phi_\alpha$ ，使得对任一水平为  $\alpha$  的检验函数  $\varphi \in \Phi_\alpha$  有不等式  $E_\theta(\varphi^*(x)) \geq E_\theta(\varphi(x))$ ，对所有的  $\theta \in \Theta_1$  都成立，则称  $\varphi^*(x)$  是水平为  $\alpha$  的一致最优势检验 (Uniformly Most Powerful Test)，简记为 UMPT。

## 一致最优无偏检验

设  $\varphi(x)$  是假设检验问题  $H_0 : \theta \in \Theta_0, H_1 : \theta \in \Theta_1$  的检验函数，若其势函数  $g_\varphi(\theta) = E_\theta(\varphi(x))$  满足

$$\begin{cases} g_\varphi(\theta) \leq \alpha, & \theta \in \Theta_0 \\ g_\varphi(\theta) \geq \alpha, & \theta \in \Theta_1 \end{cases}$$

则称  $\varphi(x)$  是水平为  $\alpha$  的无偏检验，显然，水平为  $\alpha$  的一致最优势检验一定是无偏检验。

## Karlin-Rubin 定理的方向判定口诀

单参数指数族分布，定理要求概率密度函数  $p(x, \theta)$  必须能写成这种形式：

$$p(x, \theta) = d(\theta)h(x) \exp\{c(\theta)T(x)\}$$

- $T(x)$ ：这是我们提取出来的**统计量**（充分统计量）。
- $c(\theta)$ ：这是关于参数  $\theta$  的函数。

总结出一个简单的“正负得负”规律，用来迅速判断拒绝域是  $T > C$  还是  $T < C$ 。

**如果这是离散分布题目**：你必须写出  $\gamma$ ，因为边界概率  $P(T = C) \neq 0$ 。

**因为这是连续分布题目**：边界概率  $P(T = C) = 0$ ，等号是否取、 $\gamma$  是多少都不影响积分结果。为了简洁，直接写  $\leq C$  是标准做法。

### 1. 函数 $c(\theta)$ 的单调性：

- 单调递增 ( $\nearrow$ )：记为 **正 (+)**
- 单调递减 ( $\searrow$ )：记为 **负 (-)**

### 2. 备择假设 $H_1$ 的方向：

- $H_1 : \theta > \theta_0$  (右边)：记为 **正 (+)**
- $H_1 : \theta < \theta_0$  (左边)：记为 **负 (-)**

判定法则：将这两个符号相乘：

- **正正得正 (+)**  $\rightarrow$  拒绝域为大号  $T(x) > C$
- **负负得正 (+)**  $\rightarrow$  拒绝域为大号  $T(x) > C$
- **正负得负 (-)**  $\rightarrow$  拒绝域为小号  $T(x) < C$
- **负正得负 (-)**  $\rightarrow$  拒绝域为小号  $T(x) < C$

## 第三章

## 贝叶斯统计

记作  $p(x|\theta)$ 。意味着  $\theta$  是一个**随机变量**。这里的  $p$  代表的是在  $\theta$  取某个特定值时的**条件概率密度**。

## 贝叶斯公式

$$\text{连续形式: } \pi(\theta|x) = \frac{p(x|\theta)\pi(\theta)}{\int_{\Theta} p(x|\theta)\pi(\theta)d\theta}$$

$$\text{离散形式: } P(\theta_i|X) = \frac{P(X|\theta_i)P(\theta_i)}{\sum P(X|\theta_j)P(\theta_j)}$$

风险最小的那个“最佳估计值”  $\theta^*$ ，正好就是**后验分布的期望值（均值）**  $\theta^* = E(\theta|x) = \int \theta p(\theta|x)d\theta$

## 第四章

### 性质

$\mu$  是一个  $p$  维向量, 称为均值向量。当  $A$  和  $B$  为常数矩阵时, 由定义可立即推出如下性质

$$(1) E(AX) = AE(X)$$

$$(2) E(AXB) = AE(X)B$$

$$(3) D(AX) = AD(X)A^T = A\Sigma A^T$$

$$(4) cov(AX, BY) = Acov(X, Y)B^T$$

(5) 设  $X$  为  $p$  维随机向量, 期望和协方差存在, 记  $\mu = E(X)$ ,  $\Sigma = D(X)$ ,  $A$  为  $p \times p$  常数阵, 则

$$E(X^T AX) = tr(A\Sigma) + \mu^T A\mu$$

随机向量  $X = (X_1, X_2, \dots, X_p)^T$ , 其协方差阵  $\Sigma$  都是对称阵, 同时总是半正定的。大多数情形下是正定的。

### 多元正态分布

**定义4.2.3** 若对任何非零向量  $a \in R^p$ ,  $X$  的线性组合  $a^T X$  服从一元正态分布  $N(a^T \mu, a^T V a)$ , 则称  $X$  服从  $p$  元正态分布  $N_p(\mu, V)$ 。

### 多元正态条件分布

设  $X \sim N_p(\mu, V)$ ,  $V > 0$  (正定)。我们将  $X$  分块为  $X_1$  和  $X_2$ 。

1. 给定  $X_2$  时  $X_1$  的条件分布: 服从  $N_k(\mu_{1 \cdot 2}, V_{11 \cdot 2})$ , 其中:

- 条件均值:  $\mu_{1 \cdot 2} = \mu_1 + V_{12} V_{22}^{-1} (X_2 - \mu_2)$
- 条件协方差 (舒尔补):  $V_{11 \cdot 2} = V_{11} - V_{12} V_{22}^{-1} V_{21}$

2. 给定  $X_1$  时  $X_2$  的条件分布: 服从  $N_{p-k}(\mu_{2 \cdot 1}, V_{22 \cdot 1})$ , 其中:

- 条件均值:  $\mu_{2 \cdot 1} = \mu_2 + V_{21} V_{11}^{-1} (X_1 - \mu_1)$
- 条件协方差:  $V_{22 \cdot 1} = V_{22} - V_{21} V_{11}^{-1} V_{12}$

### 多元正态分布的通用密度函数公式

$$f(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left\{-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right\}$$

## 第五章

### 符号秩和检验

设有两个总体  $F(x)$  与  $G(y)$ , 检验问题为  $H_0: F(x) = G(x), H_1: F(x) \neq G(x)$ 。如今获得成对数据  $(x_i, y_i), i = 1, 2, \dots, n$ , 令  $z_i = x_i - y_i$ , 记  $R_i$  为  $|z_i|$  在  $|z_1|, |z_2|, \dots, |z_n|$  中的秩,  $V_i$  定义为

$$V_i = \begin{cases} 1, & z_i > 0 \\ 0, & z_i \leq 0 \end{cases} \quad i = 1, 2, \dots, n$$

符号秩和检验用的统计量是  $W^+ = \sum_{i=1}^n V_i R_i$ , 这一统计量实质上是  $x_i > y_i$  的观测值的差的绝对值  $|z_i|$  的秩和。

$W^+$  是所有满足  $x_i > y_i$  的那些差值的绝对值所对应的秩之和。



#### ◇ 构造差值与秩

令:  $z_i = x_i - y_i \quad (i = 1, 2, \dots, n)$

这是每一对中的差值。

然后定义:

- $|z_i|$  是差值的绝对值
- 将所有  $|z_i|$  从小到大排序, 得到它们的秩 (rank)

记:

- $R_i$ :  $|z_i|$  在所有  $|z_1|, |z_2|, \dots, |z_n|$  中的秩 (按升序排列)
- 注意: 如果出现相等的  $|z_i|$ , 则使用平均秩处理 (如并列第3和第4, 则都取秩为3.5)

#### ◇ 定义符号变量 $V_i$

为了判断方向, 引入符号变量:

$$V_i = \begin{cases} 1, & \text{若 } z_i > 0 \Rightarrow x_i > y_i \\ 0, & \text{若 } z_i \leq 0 \Rightarrow x_i \leq y_i \end{cases}$$

☑ 这个  $V_i$  表示第  $i$  对中  $x_i$  是否大于  $y_i$

#### ◇ 核心统计量: $W^+$

定义符号秩和检验的统计量为:  $W^+ = \sum_{i=1}^n V_i R_i$

即  $W^+$  是所有满足  $x_i > y_i$  的那些差值的绝对值所对应的秩之和。

在  $H_0$  为真时,  $x_i > y_i$  与  $x_i < y_i$  出现的可能性应该是相同的, 因而在  $H_0$  为真时  $W^+$  不应过大, 也不应过小, 从而拒绝域的合理形式为:  $\{W^+ \leq d \text{ 或 } W^+ \geq c\}$

在小样本场合 ( $n \leq 20$ ), 后面附表给出了  $P(W^+ \geq c) \leq \alpha$  的临界值  $c$ ,  $d = \frac{n(n+1)}{2} - c$ ;

在大样本场合, 可以证明  $(W^+)^* = \frac{W^+ - E(W^+)}{\sqrt{\text{Var}(W^+)}}$  近似  $N(0, 1)$ , 其中  $E(W^+) = \frac{n(n+1)}{4}$ ,

$\text{Var}(W^+) = \frac{n(n+1)(2n+1)}{24}$ , 从而水平为  $\alpha$  的拒绝域为  $\{|(W^+)^*| \geq u_{1-\frac{\alpha}{2}}\}$